

Séries Temporais

Docente: Raquel Menezes



2021/2022

Projeto de Análise de Dados



Carina Ribeiro a92311

Daniela Brasileiro a92314

Índice

Introdução	3
Série Temporal escolhida	4
Gráfico da Série Temporal	4
Análise de dados	5
Modelo SARIMA(p,d,q)x(P,D,Q) _s	5
PASSO 1: Estabilizar a variância	5
PASSO 2: Ordem da diferenciação	6
PASSO 3: Cálculo do período (detetar a sazonalidade)	7
Primeiramente vamos considerar a diferenciação com d=1	8
PASSO 4: Calcular as ordens da parte sazonal	8
PASSO 5 : Calcular as ordens da parte regular	9
Qualidade do ajustamento - Análise dos resíduos	9
· Independência dos resíduos	10
· Verificar se os resíduos seguem a distribuição normal	11
· Média dos resíduos	12
· Variância dos resíduos	13
Previsões	14
Iremos agora considerar a diferenciação de ordem 2 (d=2)	17
PASSO 4: Calcular as ordens da parte sazonal	17
PASSO 5 : Calcular as ordens da parte regular	17
Qualidade do ajustamento - Análise dos resíduos	18
· Independência dos resíduos	18
· Verificar se os resíduos seguem a distribuição normal	20
· Média dos resíduos	20
· Variância dos resíduos	21
Previsões	22
Comparação dos dois modelos	26
Conclusão	27
Webgrafia	28

Introdução

Este projeto foi proposto pela docente Raquel Menezes no âmbito da Unidade Curricular de Séries Temporais do curso de Estatística Aplicada. Este consiste na análise de dados temporalmente correlacionados, aplicando o conhecimento adquirido ao longo desta UC e com o auxílio do software R, sendo este o principal objetivo. Iremos assim realizar a modelação e previsão de uma série temporal univariada. Os principais conceitos aplicados neste trabalho são referentes ao capítulo 4, modelação ARIMA de séries temporais.

Neste projeto tivemos a oportunidade de explorar a base de dados escolhida e tirar conclusões no contexto da mesma. Além disso, realizamos representações gráficas que consideramos oportunas e adequadas. Tudo contribuiu para uma melhor assimilação da matéria lecionada na UC em questão, bem como para o aperfeiçoamento do conhecimento sobre o programa utilizado R e também do Word, que foi o formato em que o trabalho foi realizado inicialmente. Além disso melhoramos a nossa capacidade de trabalho em grupo, criatividade e organização.

Conseguimos abordar todos os conteúdos pedidos e cumprir todas as tarefas propostas no tempo estipulado.

Série Temporal escolhida

Para a realização deste projeto, o nosso grupo escolheu a base de dados denominada "accdeaths" da biblioteca MASS localizada no R.

> accdeaths


	Jan	Feb	Mar	Apr	May	Jun	Jul	Aug	Sep	Oct	Nov	Dec
1973	9007	8106	8928	9137	10017	10826	11317	10744	9713	9938	9161	8927
1974	7750	6981	8038	8422	8714	9512	10120	9823	8743	9129	8710	8680
1975	8162	7306	8124	7870	9387	9556	10093	9620	8285	8466	8160	8034
1976	7717	7461	7767	7925	8623	8945	10078	9179	8037	8488	7874	8647
1977	7792	6957	7726	8106	8890	9299	10625	9302	8314	8850	8265	8796
1978	7836	6892	7791	8192	9115	9434	10484	9827	9110	9070	8633	9240

Trata-se de uma série temporal com sazonalidade e 72 observações.

A variável de interesse é uma variável discreta e representa o número de mortes acidentais nos Estados Unidos da América, sendo estes dados recolhidos mensalmente, desde 1973 até 1978.

Note-se que uma **morte acidental** é uma morte não natural causada por um acidente, um evento imprevisível como escorregões e quedas, acidentes de trânsito, envenenamento acidental, asfixia acidental ou afogamento. As mortes acidentais são diferenciadas da morte por causas naturais (doença) e de homicídios e suicídios intencionais. Uma morte acidental ainda pode ser considerada um homicídio ou suicídio se uma pessoa foi a causa não intencional.

Gráfico da Série Temporal



- Através do gráfico vemos que à primeira vista a variância parece constante, mas a média não, pelo que a série temporal não é estacionária

- Também vemos que esta parece ter sazonalidade

Análise de dados

- Começamos por utilizar os seguintes comandos, com o objetivo de chamar a série temporal e obter algumas informações gerais sobre a mesma (para uma melhor percepção desta):

```
> library(MASS)
> mortes<-accdeaths
> class(mortes)
[1] "ts"
> str(mortes)
Time-Series [1:72] from 1973 to 1979: 9007 8106 8928 9137 10017 ...
> summary(mortes)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  6892   8089   8728   8789   9323  11317
```

Como visto acima, a série temporal em estudo passará a denominar-se "mortes".

Modelo SARIMA(p,d,q)x(P,D,Q)s

Nesta fase pretende-se encontrar um modelo SARIMA (p,d,q)x(P,D,Q)s mais adequado para que posteriormente se possam fazer previsões sobre os dados em estudo.

Para encontrar este modelo iremos utilizar a Metodologia Box-Jenkins que consiste em:


- PASSO 1: Estabilizar variância
- PASSO 2: Ordem da diferenciação d=? (estabilizar tendência)
- PASSO 3: Período s=? (detetar sazonalidade)
- PASSO 4: se s diferente de 0 então é necessário identificar as ordens sazonais D=?, P=? e Q=? (Para P=1, D=Q=0, se coeficiente AR próximo de 1, então D=1)
- PASSO 5: Ordens da parte regular p=? e q=?

PASSO 1: Estabilizar a variância

Utilizamos o seguinte código para a visualização do gráfico dos dados originais e dos dados logaritmizados.

```
> par(mfrow=c(2,1))
> plot(mortes,main=" Dados originais")
> plot(log(mortes),main=" Dados logaritmizados")
```

Obtendo:



Pela observação dos gráficos vemos que não há grande diferença entre os dados originais e os logaritmizados pelo que podemos concluir que não há evidência para considerarmos que a variância não é constante e, portanto, iremos continuar a utilizar os dados originais.

PASSO 2: Ordem da diferenciação

Neste passo iremos descobrir qual a ordem da diferenciação ($d=?$) de modo a estabilizar a tendência e assim atingir a estacionariedade. A tendência dos dados pode ser visualizada no gráfico seguinte:




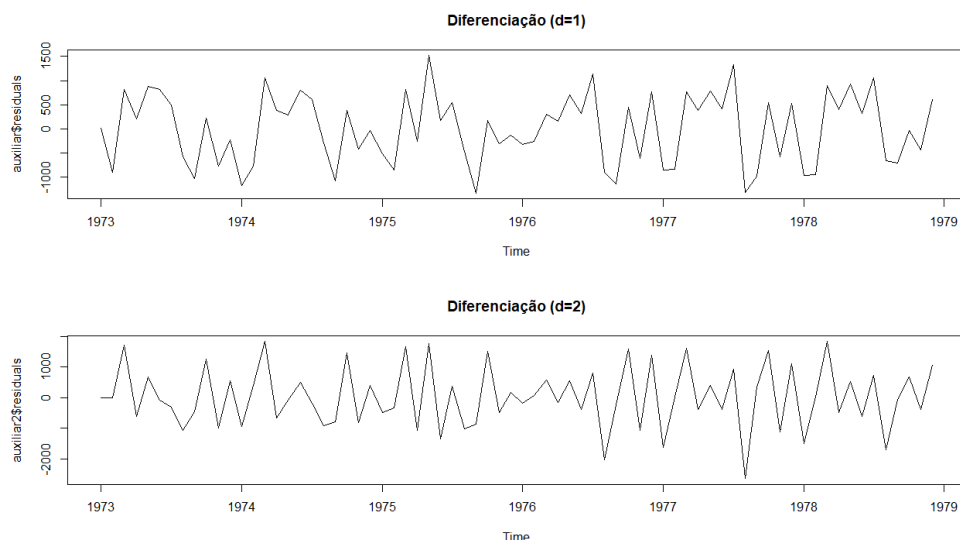
Gráfico este obtido através de:

```
> par(mfrow=c(1,1))
> plot((decompose(mortes))$trend, main="Tendência dos dados")
```

Para estabilizar esta tendência e torná-la assim constante utilizamos os seguintes comandos, que são os modelos com $d=1$ e $d=2$ e a sua comparação gráfica.

```
> par(mfrow=c(2,1))
> auxiliar = arima(mortes, order=c(0,1,0), seasonal=list(order=c(0,0,0), period=0))
> plot(auxiliar$residuals, main="Diferenciação (d=1)")
> auxiliar2 = arima(mortes, order=c(0,2,0), seasonal=list(order=c(0,0,0), period=0))
> plot(auxiliar2$residuals, main="Diferenciação (d=2)")
```

Obtendo:



Através das representações gráficas observamos que para ambas as ordens de diferenciação a tendência foi de facto estabilizada. Vemos também que existem algumas diferenças entre $d=1$ e para $d=2$ pelo que decidimos utilizar as duas e no final concluir qual o modelo mais adequado.

PASSO 3: Cálculo do período (detetar a sazonalidade)

Para detetar a sazonalidade aplicamos as seguintes instruções no R:


```
> periodogram=spectrum(as.vector(mortes), plot=F)
> imax=which.max(periodogram$spec)
> periodo=1/periodogram$freq[imax]
> periodo
[1] 12
```

Concluimos que de facto a série temporal tem sazonalidade e o seu período é igual a 12, ou seja, esta tem sazonalidade com período igual a 12 meses.

Podemos também verificar o período através do comando `decompose()`

Obtendo:

```
> plot(decompose(mortes))
```



No gráfico da parte sazonal (terceiro gráfico) podemos ver que ocorre sazonalidade com período de 1 ano (12 meses).

Visto que o período é 12 meses, achamos relevante ver em que mês do ano ocorrem os picos de mortes acidentais. Para isso utilizamos os códigos:

```
> #Ver em que mês ocorrem os picos
> which(mortes[1:12]==max(mortes[1:12]))
[1] 7
> which(mortes[12:24]==max(mortes[12:24]))
[1] 8
> which(mortes[24:36]==max(mortes[24:36]))
[1] 8
> which(mortes[36:48]==max(mortes[36:48]))
[1] 8
> which(mortes[48:60]==max(mortes[48:60]))
[1] 8
> which(mortes[60:72]==max(mortes[60:72]))
[1] 8
```

Concluimos que na maioria dos anos os picos ocorrem no mês de agosto (mês 8) com exceção do ano de 1973 em que o pico de mortes acidentais ocorreu no mês de julho (mês 7). Pensamos que estes valores se devem provavelmente à maior propensão para afogamentos no mês de agosto, aumentando assim o número de mortes acidentais.

Primeiramente vamos considerar a diferenciação com $d=1$.

PASSO 4: Calcular as ordens da parte sazonal

Primeiramente iremos descobrir o valor de D.

Para $P=1$ e $D=Q=0$, realizamos a seguinte instrução do R:

Através do output sabemos que o coeficiente tem um valor de 0.8579, valor este próximo de 1, pelo que concluimos que $D=1$, útil para efetuar os modelos vizinhos.

* (explicação detalhada da primeira linha da tabela)

Para as restantes linhas, iremos seleccionar o melhor modelo utilizando o critério de informação de Akaike (AIC = Akaike information Criteria).

Modelo	Coeficiente	Erro(S.E)	Significância	AIC
* $ARIMA(0, 1, 0) \times (1, 0, 0)_{s=12}$	Sar1: 0.8579	0.0481	Coeficiente próximo de 1	
$ARIMA(0, 1, 0) \times (1, 1, 0)_{s=12}$	Sar1: -0.3491	0.1207	Significativo	868.3
$ARIMA(0, 1, 0) \times (0, 1, 1)_{s=12}$	Sma1: -0.5665	0.1650	Significativo	864.13
$ARIMA(0, 1, 0) \times (1, 1, 1)_{s=12}$	Sar1: 0.2850 Sma1: -0.9996	0.1607 0.7138	Não significativo, aceita-se $H_0: \alpha = 0$ e $H_0: \beta = 0$	
$ARIMA(0, 1, 0) \times (2, 1, 0)_{s=12}$	Sar1: -0.4617 Sar2: -0.2928	0.1320 0.1415	Significativo	866.48
$ARIMA(0, 1, 0) \times (0, 1, 2)_{s=12}$	Sma1: -0.5935 Sma2: -0.1738	0.2755 0.2080	Não significativo, aceita-se $H_0: \beta_2 = 0$	

Escolhemos assim o modelo com menor AIC :

$$ARIMA(p, 1, q) \times (0, 1, 1)_{s=12}$$

PASSO 5: Calcular as ordens da parte regular

Novamente, iremos selecionar o melhor modelo utilizando o critério de informação de Akaike (AIC = Akaike information Criteria).

Modelo	Coeficiente	Erro(S.E)	Significância	AIC
$ARIMA(0, 1, 0) \times (0, 1, 1)_{s=12}$	Sma1: -0.5665	0.1650	Significativo	864.13
$ARIMA(1, 1, 0) \times (0, 1, 1)_{s=12}$	Ar1: -0.3304 Sma1: -0.5893	0.1225 0.1807	Significativo	859.28
$ARIMA(0, 1, 1) \times (0, 1, 1)_{s=12}$	Ma1: -0.4303 Sma1: -0.5528	0.1228 0.1784	Significativo	856.88
$ARIMA(1, 1, 1) \times (0, 1, 1)_{s=12}$	Ar1: 0.0979 Ma1: -0.5109 Sma1: -0.5437	0.3111 0.2736 0.1784	Não significativo, aceita-se $H_0: \phi = 0$	_____
$ARIMA(2, 1, 0) \times (0, 1, 1)_{s=12}$	Ar1: -0.4016 Ar2: -0.2117 Sma1: -0.5498	0.1272 0.1268 0.1768	Não significativo, aceita-se $H_0: \phi_2 = 0$	_____
$ARIMA(0, 1, 2) \times (0, 1, 1)_{s=12}$	Ma1: -0.4081 Ma2: -0.0518 Sma1: -0.5417	0.1341 0.1478 0.1782	Não significativo, aceita-se $H_0: \theta_2 = 0$	_____

Escolhemos assim o modelo com menor AIC :

$$ARIMA(0, 1, 1) \times (0, 1, 1)_{s=12}$$

Qualidade do ajustamento - Análise dos resíduos

Neste passo vamos verificar se os resíduos são ruídos brancos, ou seja, se cumprem os seguintes pressupostos:

- ϵ_t são independentes (não correlacionados);
- ϵ_t seguem a distribuição normal;
- A média de ϵ_t é zero ($E[\epsilon_t] = 0$);
- A variância de ϵ_t é constante, ou seja, homocedástica.

Começamos por denominar o modelo escolhido por modelo1.

```
> modelo1 <- arima(mortes, order=c(0,1,1), seasonal=list(order=c(0,1,1), period=12))
> names(modelo1)
[1] "coef"      "sigma2"    "var.coef"  "mask"      "loglik"    "aic"
[7] "arma"      "residuals" "call"      "series"    "code"      "n.cond"
[13] "nobs"      "model"
>
> #variância estimada dos erros
> modelo1$sigma2
[1] 99346.89
```

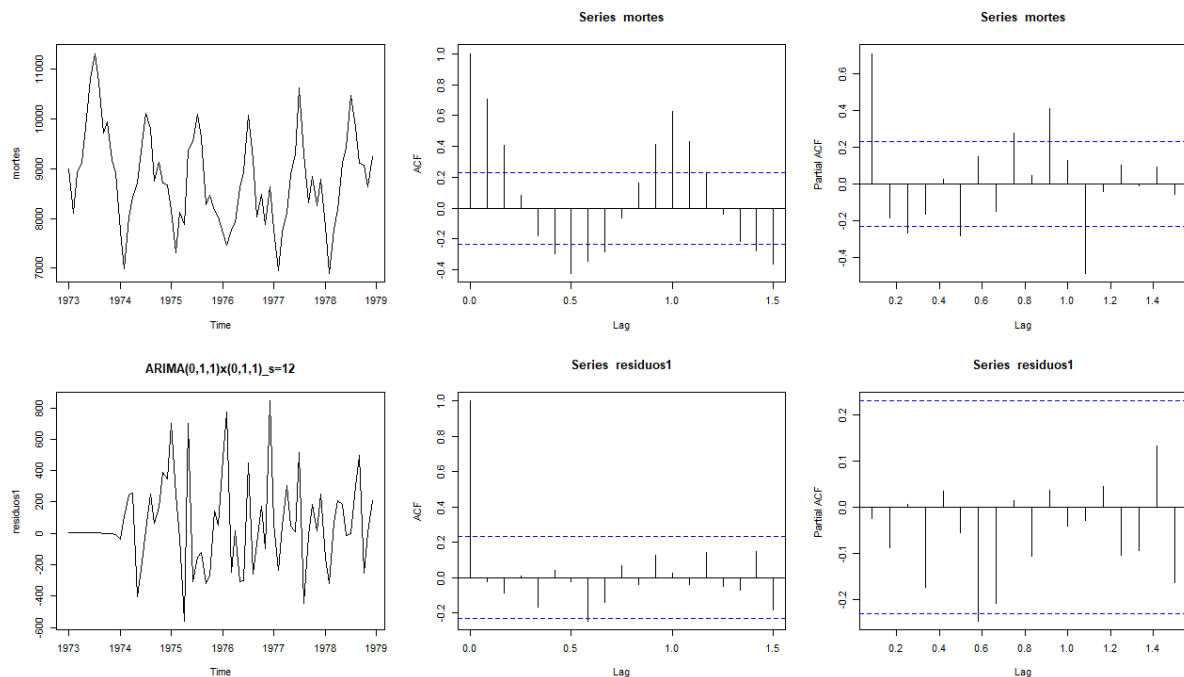
Através do output observamos que a variância estimada dos erros do modelo escolhido é 99346.8.

❖ Independência dos resíduos

Começamos por denominar os resíduos do modelo de `residuos1` e de seguida realizamos os gráficos destes, e das respectivas funções de autocorrelação total e parcial. Para tal, realizamos os comandos:

```
> residuos1=modelo1$residuals
> par(mfrow=c(2,3))
> plot(mortes)
> acf(mortes)
> pacf(mortes)
> # testar independência dos resíduos
> plot(residuos1, main="ARIMA(0,1,1)x(0,1,1)_s=12")
> acf(residuos1)
> pacf(residuos1)
```


Obtendo:



No quinto gráfico está representada a FAC dos resíduos e no sexto a FACP dos mesmos. Destes gráficos podemos concluir que não há evidências para rejeitar a independência dos resíduos, logo este pressuposto está verificado.

De forma a poder observar melhor que os resíduos são independentes vamos considerar o grau de significância de 99%.

```
> par(mfrow=c(1,3))
> plot(residuos1, main="ARIMA(0,1,1)x(0,1,1)_s=12")
> acf(residuos1,ci=0.99)
> pacf(residuos1,ci=0.99)
```



Também podemos verificar a independência dos resíduos recorrendo seguinte teste:

```
> Box.test(residuos1)
```

Box-Pierce test

```
data: residuos1
x-squared = 0.041252, df = 1, p-value = 0.8391
```

Sendo $p\text{-value}=0.8391$ aceita-se a hipótese nula ($H_0: \varepsilon_t$ são independentes) para os níveis de significância usuais (5% e 10%), logo concluímos que os resíduos são independentes.

❖ verificar se os resíduos seguem a distribuição normal

```
> library(nortest)
> lillie.test(residuos1)

Lilliefors (Kolmogorov-Smirnov) normality test


data: residuos1
D = 0.1339, p-value = 0.002693

> qqnorm(residuos1)
> qqline(residuos1)
> hist(residuos1)
```

Nos comandos anteriores recorremos à biblioteca nortest para podermos utilizar o teste Lilliefors (Kolmogorov-Smirnov), sendo o teste utilizado para testar a normalidade em amostras grandes (mais de 30 observações). Observar que o valor p é igual a 0.002693 pelo que rejeitamos a hipótese nula ($H_0: \varepsilon_t$ segue uma distribuição normal) para

os níveis de significância usuais, ou seja, os resíduos não seguem uma distribuição normal.

Visualizamos também os seguintes gráficos:



Como é possível ver nas representações gráficas os resíduos não seguem uma distribuição normal, obtendo assim mesma conclusão que anteriormente.

Os resíduos não verificam este pressuposto.

❖ Média dos resíduos

Para testar se a média dos resíduos tem o valor de 0 utilizamos o teste de T de Student, uma vez que é um teste paramétrico para testar a média. Utilizamos os comandos:

```
> t.test(residuos1)

One sample t-test

data:  residuos1
t = 1.7754, df = 71, p-value = 0.08011
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -7.240938 124.911706
sample estimates:
mean of x
 58.83538
```

Obtém-se o valor p 0.08011 não rejeitando a hipótese nula, $H_0: E[\varepsilon_t] = 0$, concluindo assim que a média dos resíduos é igual a zero para os níveis de significância usuais.



Os resíduos verificam este pressuposto.

❖ variância dos resíduos

Para verificar se a variância dos resíduos é constante obtemos a representação gráfica dos resíduos através dos comandos:

Obtendo:

```
> par(mfrow=c(1,2))
> plot(as.vector(residuos1))
> plot(residuos1)
```

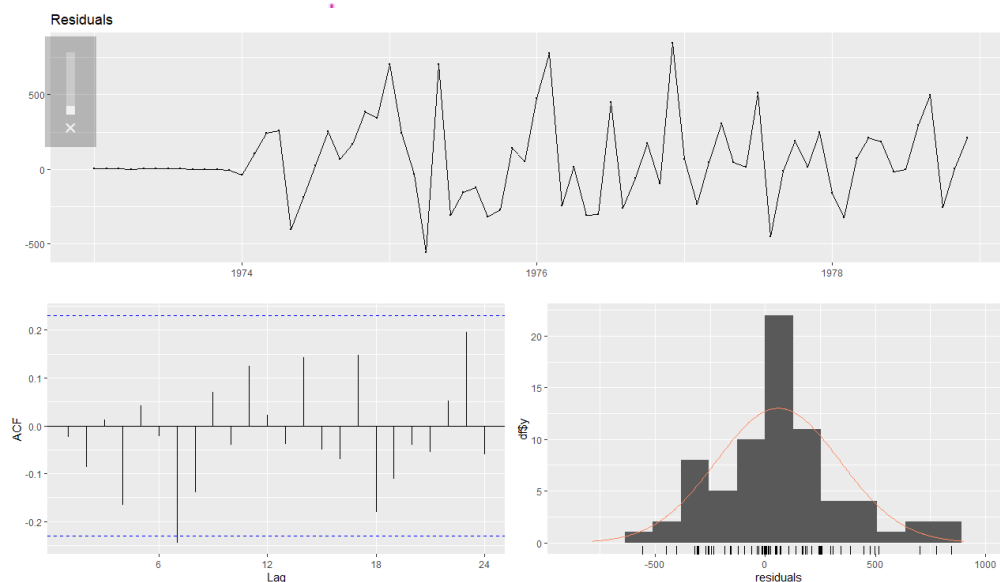


Concluimos que não há evidências para considerar que a variância não é constante uma vez que não se regista qualquer padrão nos gráficos anteriores. Existindo assim homocedasticidade.

Os resíduos verificam este pressuposto.

Além do suprarreferido também podemos utilizar os seguintes comandos para ter uma ideia geral do comportamento dos resíduos e confirmar o que já tínhamos concluído.

```
> library(forecast)
> checkresiduals(residuos1)
```



Previsões

Apesar dos resíduos do modelo não validarem um dos pressupostos (normalidade) iremos fazer previsões utilizando o mesmo.

- De modo a validar ou não modelo, iremos ignorar as últimas 24 observações (2 anos) e fazer previsões para esse período ignorado comparar os valores estimados com os observados. Ou seja, estimar $x_{49}, \dots, x_{71}, x_{72}$.

Começamos por denominar o modelo escolhido de m1 e a atribuir um nome às previsões.

```
> m1 = arima(mortes[1:48], order=c(0,1,1), seasonal=list(order=c(0,1,1), period=12))
> previsoes <- predict(m1, n.ahead = 24)
> mortes[49:72]
> previsoes$pred
> previsoes$se
```

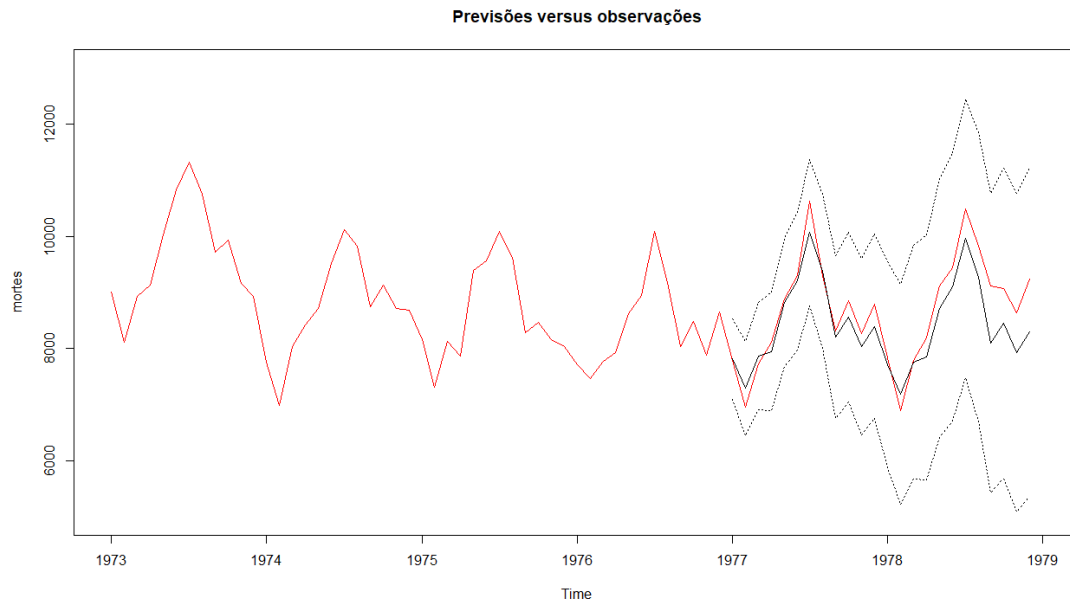
Obtemos para os valores previstos e respetivos erros:

Mês	Valores observados	Valores previstos	Erro
Jan 1977	7792	7814.650	365.5615
Fev 1977	6957	7290.022	430.2666
Mar 1977	7726	7862.383	486.4395
Abril 1977	8106	7948.237	536.7657
Maio 1977	8890	8817.406	582.7620
Jun 1977	9299	9199.222	625.3844
Jul 1977	10625	10063.322	665.2817
Agos 1977	9302	9374.924	702.9180
Set 1977	8314	8200.390	738.6392
Out 1977	8850	8556.643	772.7107
Nov 1977	8265	8033.055	805.3421
Dez 1977	8796	8396.007	836.7019
Jan 1978	7836	7710.393	938.4360
Fev 1978	6892	7185.764	1001.1110
Mar 1978	7791	7758.125	1060.0869
Abril 1978	8192	7843.979	1115.9504
Maio 1978	9115	8713.149	1169.1477
Jun 1978	9434	9094.964	1220.0277
Jul 1978	10484	9959.064	1268.8690
Agos 1978	9827	9270.667	1315.8988
Set 1978	9110	8096.132	1361.3048
Out 1978	9070	8452.385	1405.2444
Nov 1978	8633	7928.797	1447.8511
Dez 1978	9240	8291.749	1489.2394

Para obter o gráfico da série original com as previsões e os intervalos de confiança a 95% utilizamos o comando:

```
> ts.plot(mortes, xlim=c(1973,1979), ylim=c(5000,13000), col="red", main="Previsões versus observações")
> lines(ts(previsoes$pred, start=1977, deltat=1/12))
> low = previsoes$pred - 1.96*previsoes$se
> upper = previsoes$pred + 1.96*previsoes$se
> lines(ts(low, start=1977, deltat=1/12), lty=3)
> lines(ts(upper, start=1977, deltat=1/12), lty=3)
```

O gráfico obtido foi:



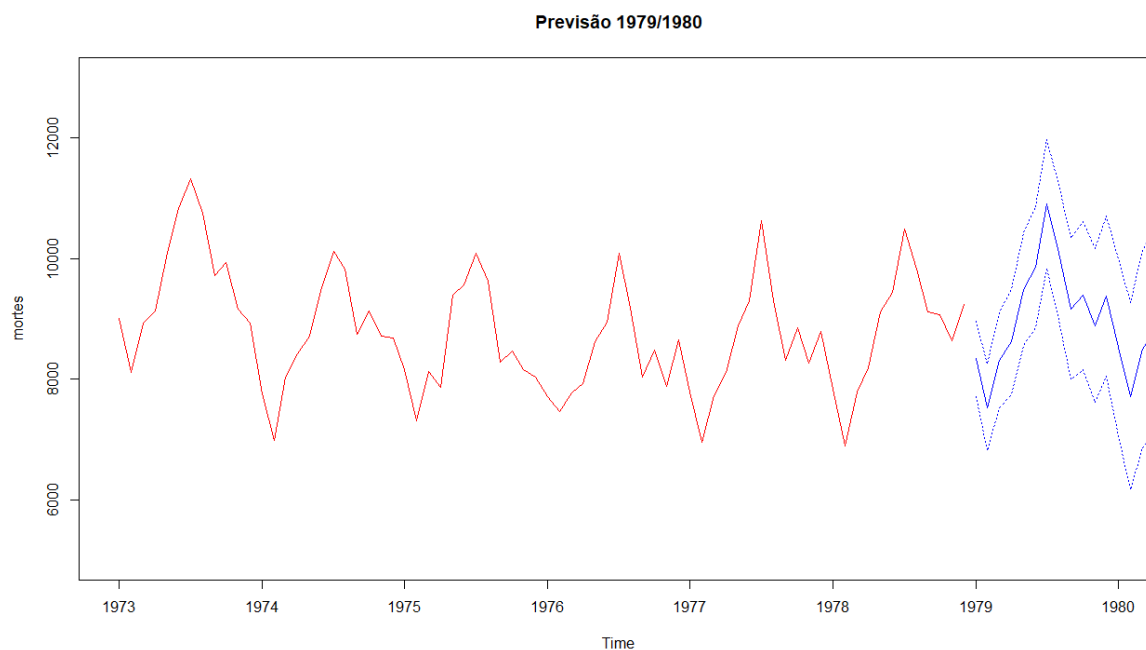
Deduzimos assim que as previsões apresentam valores próximos das observações, apesar de observarmos algum erro de previsão. Isto é possível observar a partir da tabela, mas também do gráfico onde a linha de cor preta (previsões) está bastante próxima da linha de cor vermelha (série original). Concluimos assim que este modelo é válido e adequado.

- Considerando agora o total das observações vamos produzir previsões para o futuro. Escolhemos prever os dados para 2 anos (1979 e 1980).

Recorremos aos comandos:

```
> ts.plot(mortes, xlim=c(1973,1980), ylim=c(5000,13000), col="red", main="Previsão 1979/1980")
> m1 = arima(mortes, order=c(0,1,1), seasonal=list(order=c(0,1,1), period=12))
> previsoes79_80 <- predict(m1, n.ahead = 24)
> lines(ts(previsoes79_80$pred, start=1979, deltat=1/12), col="blue")
> low = previsoes79_80$pred - 1.96*previsoes79_80$se
> upper = previsoes79_80$pred + 1.96*previsoes79_80$se
> lines(ts(low, start=1979, deltat=1/12), lty=3, col="blue")
> lines(ts(upper, start=1979, deltat=1/12), lty=3, col="blue")
```

Obtemos assim o seguinte gráfico, em que a linha de cor azul representa as previsões dos anos 1979 e 1980, e a linha de cor vermelha a série original.



Através de : `> previsoes79_80$pred` `> previsoes79_80$se`

Obtemos para os valores previstos e respectivos erros:

Mês	Valores previstos	Erro
Jan 1979	8336.061	315.4481
Fev 1979	7531.829	363.0056
Mar 1979	8314.644	405.0168
Abril 1979	8616.869	443.0623
Mai 1979	9488.913	478.0897
Jun 1979	9859.757	510.7204
Jul 1979	10907.470	541.3879
Agos 1979	10086.508	540.4090
Set 1979	9164.959	598.0234
Out 1979	9384.259	624.4178
Nov 1979	8884.974	649.7408
Dez 1979	9376.574	674.1133
Jan 1980	8522.584	746.7030
Fev 1980	7718.352	790.6702
Mar 1980	8501.167	832.3180
Abril 1980	8803.392	871.9798
Mai 1980	9675.435	909.9127
Jun 1980	10046.280	946.3272

Jul 1980	11093.993	981.3914
Agos 1980	10273.031	1015.2453
Set 1980	9351.482	1048.0062
Out 1980	9570.782	1079.7735
Nov 1980	9071.497	1110.6326
Dez 1980	9563.097	1140.6572

Iremos agora considerar a diferenciação de ordem 2 ($d=2$)

Iremos proceder de forma análoga à diferenciação de ordem 1, isto é, a mesma metodologia utilizada anteriormente, pelo que não iremos explicar tão detalhadamente os passos percorridos dando mais relevância aos resultados pertinentes. Além disso, é importante referir também que omitimos o passo 3 da detecção da sazonalidade uma vez que se mantém inalterado, ou seja o período permanece $s=12$.

PASSO 4: Calcular as ordens da parte sazonal

Modelo	Coeficiente	Erro(S.E)	Significância	AIC
* $ARIMA(0, 2, 0) \times (1, 0, 0)_{s=12}$	Sar1: 0.7890	0.0621	Coeficiente próximo de 1	_____
$ARIMA(0, 2, 0) \times (1, 1, 0)_{s=12}$	Sar1: -0.3467	0.1180	Significativo	917.4
$ARIMA(0, 2, 0) \times (0, 1, 1)_{s=12}$	Sma1: -0.5665	0.1624	Significativo	912.82
$ARIMA(0, 2, 0) \times (1, 1, 1)_{s=12}$	Sar1: 0.2292 Sma1: -0.8051	0.2790 0.4450	Não significativo, aceita-se $H_0: \alpha = 0$ e $H_0: \beta = 0$	_____
$ARIMA(0, 2, 0) \times (2, 1, 0)_{s=12}$	Sar1: -0.4670 Sar2: -0.3392	0.1258 0.1385	Significativo	914.26
$ARIMA(0, 2, 0) \times (0, 1, 2)_{s=12}$	Sma1: -0.5550 Sma2: -0.1692	0.2155 0.1914	Não significativo, aceita-se $H_0: \beta_2 = 0$	_____

Escolhemos assim o modelo com menor AIC :

$$ARIMA(p, 2, q) \times (0, 1, 1)_{s=12}$$

PASSO 5: Calcular as ordens da parte regular

Modelo	Coeficiente	Erro(S.E)	Significância	AIC
$ARIMA(0, 2, 0) \times (0, 1, 1)_{s=12}$	Sma1: -0.5665	0.1624	Significativo	912.82
$ARIMA(1, 2, 0) \times (0, 1, 1)_{s=12}$	Ar1: -0.5926 Sma1: -0.6633	0.1045 0.2097	Significativo	889.56
$ARIMA(0, 2, 1) \times (0, 1, 1)_{s=12}$	Ma1: -0.9985	0.0556	Significativo	862.56

	Sma1: -0.5598	0.1698		
ARIMA(1, 2, 1) × (0, 1, 1)_{s=12}	Ar1: -0.3329 Ma1: -0.9983 Sma1: -0.5972	0.1235 0.0599 0.1909	Significativo	857.78
ARIMA(2, 2, 0) × (0, 1, 1)_{s=12}	Ar1: -0.8988 Ar2: -0.5042 Sma1: -0.6337	0.1135 0.1123 0.2013	Significativo	874.62
ARIMA(0, 2, 2) × (0, 1, 1)_{s=12}	Ma1: -1.4659 Ma2: 0.4671 Sma1: -0.5799	0.1514 0.1390 0.1911	Significativo	854.96

Escolhemos assim o modelo com menor AIC :

$$\text{ARIMA}(0, 2, 2) \times (0, 1, 1)_{s=12}$$

Qualidade do ajustamento - Análise dos resíduos

O modelo escolhido passará a ser denominado de modelo2.

```
> modelo2 <- arima(mortes, order=c(0,2,2), seasonal=list(order=c(0,1,1), period=12))
> names(modelo2)
[1] "coef"      "sigma2"    "var.coef"  "mask"      "loglik"    "aic"
[7] "arma"      "residuals" "call"      "series"    "code"      "n.cond"
[13] "nobs"      "model"
> #variancia estimadas dos erros
> modelo2$sigma2
[1] 96190.12
```

Através do resultado do comando anterior observamos que a variância estimada dos erros do modelo escolhido é igual a 96190.12.

Primeiramente denominamos os resíduos de residuos2 para em seguida verificar se são ruído branco.

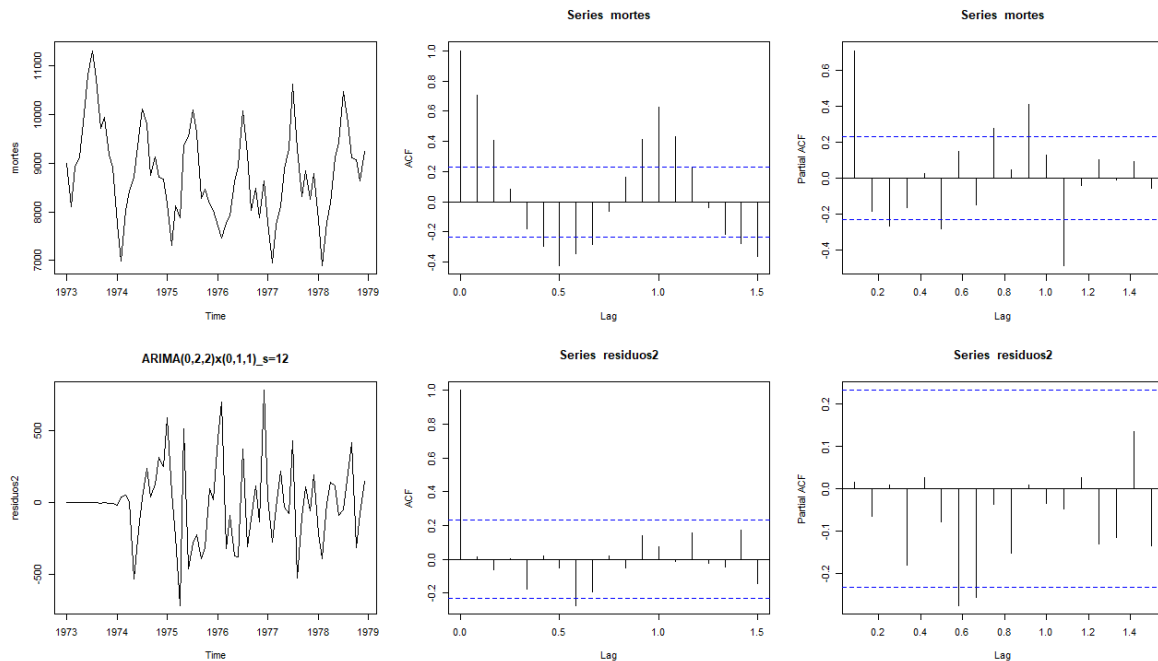
```
> residuos2 <- modelo2$residuals
```

❖ Independência dos resíduos

Realizamos os gráficos dos resíduos2 e das respetivas funções de autocorrelação total e parcial. Para tal, realizamos os comandos:

```
> residuos2 <- modelo2$residuals
> par(mfrow=c(2,3))
> plot(mortes)
> acf(mortes)
> pacf(mortes)
> # testar independência dos resíduos
> plot(residuos2, main="ARIMA(0,2,2)x(0,1,1)_s=12")
> acf(residuos2)
> pacf(residuos2)
```

Obtendo:

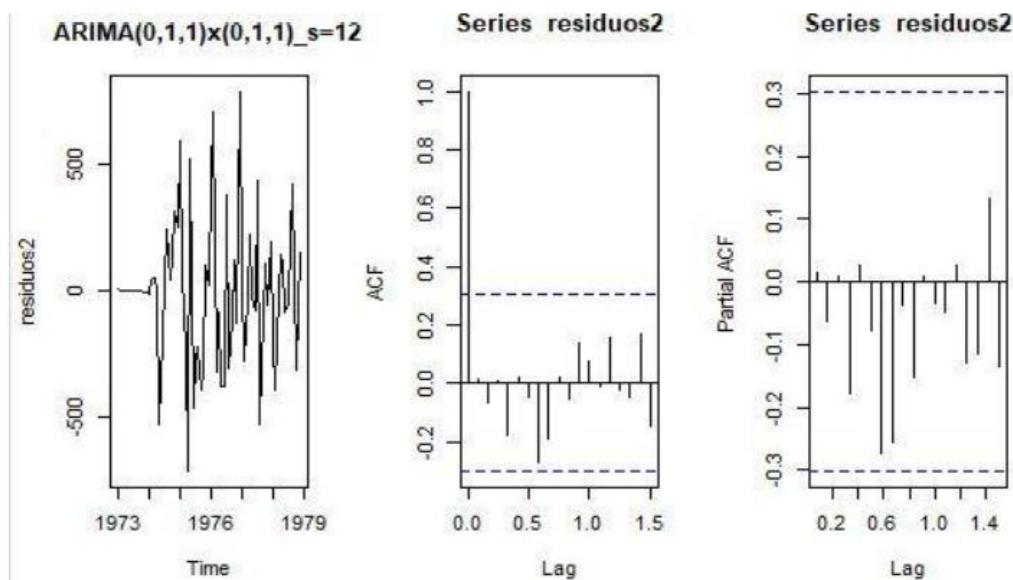


Através dos gráficos da função de autocorrelação e da função de autocorrelação parcial (quinto e sexto gráfico) podemos deduzir que não há fortes evidências para considerar que os resíduos não são independentes.

Para retirarmos esta conclusão com maior certeza iremos considerar o nível de significância a 99%.

```
> par(mfrow=c(1,3))
> plot(residuos2, main="ARIMA(0,1,1)x(0,1,1)_s=12")
> acf(residuos2,ci=0.99)
> pacf(residuos2,ci=0.99)
```

Obtendo:



Podemos tirar a mesma conclusão através do seguinte teste de hipótese Box- Pierce ou Ljung – Box.

```
> Box.test(resíduos2)
```

Box-Pierce test

```
data: resíduos2
X-squared = 0.013953, df = 1, p-value = 0.906
```

Como o valor p deste teste para os resíduos é 0.906 não há evidências para rejeitar a hipótese nula ($H_0: \varepsilon_t$ são independentes) para os níveis de significância usuais. Concluindo que os resíduos são independentes.

❖ verificar se os resíduos seguem a distribuição normal



```
> library(nortest)
> lillie.test(resíduos2)
```

Lilliefors (Kolmogorov-Smirnov) normality test

```
data: resíduos2
D = 0.11283, p-value = 0.02384
```

Através do teste Lilliefors (Kolmogorov-Smirnov) da biblioteca nortest (comandos ilustrados acima), obtivemos o valor p igual 0.02384 sendo que não se rejeita a hipótese nula, $H_0: \varepsilon_t$ segue uma distribuição normal, para o nível de significância de 1%. Concluindo que os resíduos seguem uma distribuição normal, podemos também fazer a mesma análise a partir dos seguintes gráficos.

```
> par(mfrow=c(1,2))
> qqnorm(resíduos2)
> qqline(resíduos2)
> hist(resíduos2)
```



❖ Média dos resíduos

De modo a verificar se a média dos resíduos é igual a zero utilizamos o teste T de student.

```
> t.test(residuos2)

One Sample t-test



data:  residuos2
t = -0.23318, df = 71, p-value = 0.8163
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -73.54928  58.14805
sample estimates:
mean of x
-7.700618
```

O valor p resultante do comando anterior é 0.8163 portanto não rejeitamos a hipótese nula, $H_0: E[\varepsilon_t] = 0$, deduzindo que os resíduos têm valor médio igual a 0 para os valores de significância usuais.

❖ Variância dos resíduos

Com a finalidade de analisar a variância dos resíduos iremos recorrer à representação gráfica deste.

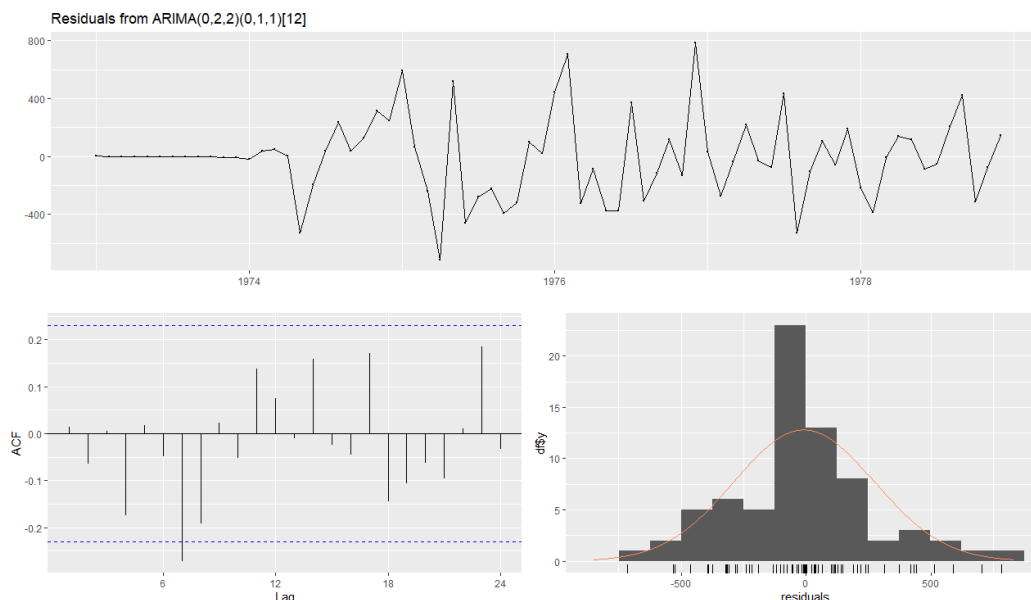
```
> plot(as.vector(residuos2))
> plot(residuos2)
```



Tendo em conta que os gráficos não apresentam nenhum padrão, não há evidências para não considerar a variância dos resíduos constante. Existindo assim homocedasticidade.

Também podemos fazer uma análise extra dos resíduos de forma a reforçar as conclusões anteriores.

```
> library(forecast)
> checkresiduals(modelo2)
```



Previsões

- De modo a validar ou não modelo, iremos ignorar as últimas 24 observações (2 anos) e fazer previsões para esse período ignorado comparar os valores estimados com os observados. Ou seja, estimar $x_{49}, \dots, x_{71}, x_{72}$.

Começamos por denominar o modelo escolhido anteriormente por m2 e as previsões por previsoes2.

```
> m2 = arima(mortes[1:48], order=c(0,2,2), seasonal=list(order=c(0,1,1), period=12))
> previsoes2 <- predict(m2, n.ahead = 24)
> mortes[49:72]
> previsoes2$pred
> previsoes2$se
```

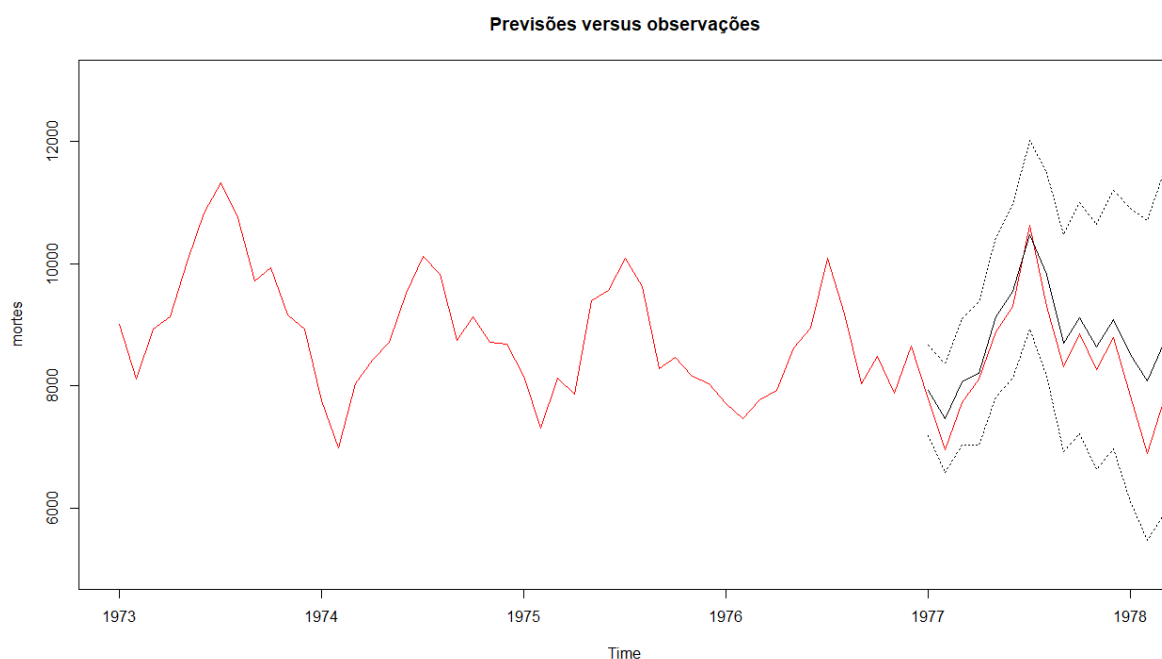
Resultando os seguintes valores previstos e os respetivos erros.

Mês	Valores observados	Valores previstos	Erro
Jan 1977	7792	7922.572	376.0704
Fev 1977	6957	7470.875	455.2374
Mar 1977	7726	8070.219	527.7833
Abril 1977	8106	8205.005	596.1352
Maio 1977	8890	9122.553	661.5987
Jun 1977	9299	9540.645	724.9608
Jul 1977	10625	10477.790	786.7330
Agos 1977	9302	9822.336	847.2666
Set 1977	8314	8696.856	906.8129
Out 1977	8850	9110.071	965.5576
Nov 1977	8265	8634.433	1023.6415

Dez 1977	8796	9082.688	1081.1740
Jan 1978	7836	8505.544	1226.2916
Fev 1978	6892	8084.293	1331.9023
Mar 1978	7791	8714.083	1434.7054
Abril 1978	8192	8879.314	1535.2695
Mai 1978	9115	9827.307	1634.0126
Jun 1978	9434	10275.844	1731.2506
Jul 1978	10484	11243.434	1827.2276
Agos 1978	9827	10618.425	1922.1363
Set 1978	9110	9523.390	2016.1313
Out 1978	9070	9967.050	2109.3381
Nov 1978	8633	9521.858	2201.8600
Dez 1978	9240	10000.557	2293.7833

Criamos um gráfico com a série temporal original (mortes), as previsões e os intervalos de previsão a 95%.

```
> ts.plot(mortes, xlim=c(1973,1978), ylim=c(5000,13000), col="red", main="Previsões versus observações")
> lines(ts(previsoes2$pred, start=1977, deltat=1/12))
> low = previsoes2$pred - 1.96*previsoes2$se
> upper = previsoes2$pred + 1.96*previsoes2$se
> lines(ts(low, start=1977, deltat=1/12), lty=3)
> lines(ts(upper, start=1977, deltat=1/12), lty=3)
```




Esta representação gráfica permite-nos uma melhor interpretação da previsão, uma vez que é possível observar que os valores previstos se aproximam dos valores realmente observados. Recorrendo à tabela podemos visualizar o mesmo, concluindo assim que o modelo é adequado.

- Iremos agora fazer previsão para os anos 1979 e 1980, ou seja, previsões para o futuro uma vez que estes anos não foram observados.

Recorrendo ao software R, utilizamos a seguinte instrução:

```
> ts.plot(mortes, xlim=c(1973,1980), ylim=c(5000,13000), col="red", main="Previsão 1979/1980")
> m2 = arima(mortes, order=c(0,2,2), seasonal=list(order=c(0,1,1), period=12))
> previsoes79_80 <- predict(m1, n.ahead = 24)
> lines(ts(previsoes79_80$pred, start=1979, deltat=1/12), col="blue")
> low = previsoes79_80$pred - 1.96*previsoes79_80$se
> upper = previsoes79_80$pred + 1.96*previsoes79_80$se
> lines(ts(low, start=1979, deltat=1/12), lty=3, col="blue")
> lines(ts(upper, start=1979, deltat=1/12), lty=3, col="blue")
.
```

Resultando a seguinte representação gráfica da previsão e com os respectivos intervalos de previsão (valores previstos estão representados a azul e a vermelho a serie original).



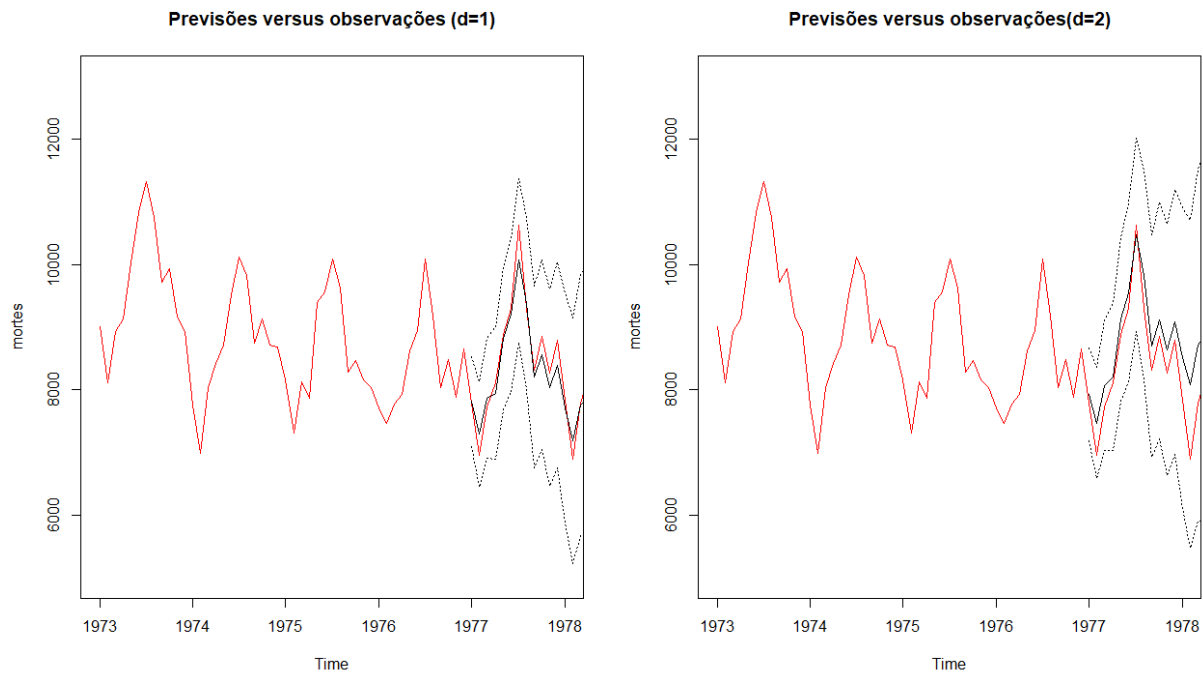
Utilizando `> previsoes79_80$pred` `> previsoes79_80$se` :

Obtemos:

Mês	Valores previstos	Erro
Jan 1979	8409.849	314.5031
Fev 1979	7659.204	360.5742
Mar 1979	8486.608	403.5404
Abril 1979	8828.264	444.3038
Mai 1979	9746.304	483.4221
Jun 1979	10170.902	521.2662
Jul 1979	11253.943	558.0954
Agos 1979	10486.042	594.0988
Set 1979	9600.179	629.4183

Out 1979	9875.404	664.1633
Nov 1979	9421.648	698.4195
Dez 1979	9944.561	732.2559
Jan 1980	9174.757	815.0840
Fev 1980	8445.318	870.2077
Mar 1980	9293.929	924.0025
Abril 1980	9656.791	976.6884
Mai 1980	10596.037	1028.4361
Jun 1980	11041.841	1079.3807
Jul 1980	12146.008	1129.6311
Agos 1980	11399.394	1179.2763
Set 1980	10534.736	1228.3898
Out 1980	10831.167	1277.0332
Nov 1980	10398.618	1325.2585
Dez 1980	10942.737	1373.1099

Comparação dos dois modelos



Comparando os dois gráficos das previsões já referidos acima, observamos que os valores previstos se aproximam mais dos valores observados para a diferenciação de ordem 1, pelo que este será o melhor modelo. No entanto, este modelo falha um dos pressupostos do ruído branco como visto anteriormente. Concluimos assim que no limite escolheríamos o modelo $ARIMA(0, 1, 1) \times (0, 1, 1)_{s=12}$.

Conclusão

Este projeto foi realizado em conjunto pelo grupo, desde a pesquisa e recolha de informação sobre a série temporal `accdeaths`, até à realização deste documento, passando pela realização em si do script do R.

Também pensamos em conjunto qual seria a estrutura do trabalho, bem como de que forma poderíamos tornar este mais apelativo e sólido. Em adição achamos que este trabalho de projeto contribuiu para o desenvolvimento das nossas capacidades de pesquisa, de utilização do R e a respetiva realização de gráficos, criatividade e sobretudo no desenvolvimento da aplicação da matéria lecionada na UC de Séries Temporais. Com este trabalho foi possível estudar de que forma evolui o número de mortes acidentais nos Estados Unidos da América, ao longo dos anos, no nosso caso desde 1973 a 1978. Também fomos capazes de realizar uma modelação e previsão da nossa série, no nosso caso com diferentes ordens de diferenciação ($d=1$ e $d=2$). Percebemos que este trabalho reforçou bastante a nossa aprendizagem e deu-nos a oportunidade de explorar a matéria de uma forma mais interessante.

Após a realização deste, podemos afirmar que enriquecemos o nosso conhecimento. Além disso, o trabalho dinamizado permitiu também o desenvolvimento do estímulo do raciocínio, a capacidade de trabalho em grupo, a responsabilidade, criatividade e autonomia.

Em suma, consideramos que os objetivos do mesmo foram alcançados e corresponderam às expectativas da professora responsável pela unidade curricular e do grupo nomeadamente por ter potenciado espaços/ momentos de partilha, aprendizagem e reflexão conjunta no contexto académico, no desenvolvimento de competências e atitudes em termos de partilha e colaboração. A partir da voz da professora foi também possível recolher informações relevantes que permitissem uma melhor compreensão das oportunidades de aprendizagem no contexto de trabalho.

Tendo em vista o exposto, considera-se possível formular um modelo ARIMA adequado aos dados, de forma a obter boas previsões. Para isto, foi fundamental aplicar o conhecimento adquirido ao longo desta UC.

webgrafia

<https://facilitaseguros.com.br/blog/seguro-morte-acidental/>

https://pt.wikipedia.org/wiki/Morte_acidental